

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



PHÂN TÍCH DỮ LIỆU KHÁCH HÀNG
VIỄN THÔNG

Nhóm 15			
Sinh viên thực hiện:			
STT	Họ tên	MSSV	Ngành
1	Trương Thế Minh Khánh	23520727	KHDL
2	Trần Anh Duy	23520389	KHDL
3	Nguyễn Văn Tiên	23521580	KHDL

TP. HỒ CHÍ MINH – 12/2025

1. GIỚI THIỆU

Đề tài tập trung giải quyết bài toán phân tích hành vi rời bỏ của khách hàng (Customer Churn) trong lĩnh vực viễn thông, một vấn đề cấp thiết ảnh hưởng trực tiếp đến doanh thu của doanh nghiệp. Thay vì chỉ dừng lại ở việc thống kê mô tả, chúng tôi thực hiện chuyển đổi bài toán kinh doanh thành quy trình khai phá dữ liệu, áp dụng các kỹ thuật làm sạch, trích xuất đặc trưng và xây dựng mô hình phân lớp để dự đoán rủi ro. Thông qua sự kết hợp giữa ngôn ngữ Python để xử lý số liệu và Power BI để trực quan hóa, mục tiêu của đề tài là đo lường mức độ ảnh hưởng của các yếu tố như loại hình hợp đồng, phương thức thanh toán và dịch vụ Internet đến quyết định của khách hàng. Kết quả của đề tài là xây dựng thành công Dashboard trên Power BI, giúp trực quan hóa dữ liệu và phát hiện sớm những nhóm khách hàng có nguy cơ rời bỏ cao.

Bộ dữ liệu phục vụ phân tích là bộ "Telco Customer Churn" được chúng tôi tham khảo và trích xuất từ kho dữ liệu mở Kaggle [1]. Đây là đề tài chúng tôi tự thiết kế quy trình phân tích và xây dựng báo cáo, không sao chép từ bất kỳ đồ án mẫu nào trước đó. Trong quá trình thực hiện, chúng tôi có tham khảo cấu trúc các biến số từ tài liệu gốc của bộ dữ liệu để đảm bảo tính chính xác và minh bạch. Toàn bộ phần mã nguồn xử lý dữ liệu (Data Pre-processing), kịch bản xây dựng Dashboard và các nhận định phân tích đều được chúng tôi tự phát triển để đáp ứng yêu cầu riêng biệt của môn học Phân tích dữ liệu.

2. MÔ TẢ BỘ DỮ LIỆU

Tên: Bộ dữ liệu "Telco Customer Churn".

Nguồn: Bộ dữ liệu phân tích được tham khảo tại nền tảng Kaggle [1].

Mô tả: Bộ dữ liệu bao gồm 7.043 dòng tương ứng với 7.043 khách hàng và được mô tả thông qua 21 thuộc tính được phân nhóm logic thành 3 mảng chính: Thông tin nhân khẩu học, Thông tin tài khoản và Các dịch vụ đăng ký.

STT	Tên cột	Kiểu dữ liệu	Giải thích
1	customerID	object	Mã số định danh duy nhất cho từng khách hàng.
2	gender	object	Giới tính của khách hàng.
3	Churn	object	Xác định khách hàng có rời bỏ dịch vụ hay không.
4	tenure	int64	Số tháng khách hàng gắn bó với công ty.
5	MonthlyCharges	float64	Số tiền cước phí khách hàng phải trả hàng tháng.
6	TotalCharges	object	Tổng doanh thu thu được từ khách hàng.
7	Contract	object	Loại hình hợp đồng (Yếu tố ảnh hưởng mạnh nhất đến Churn).

8	PaymentMethod	object	Phương thức thanh toán cước phí.
9	MultipleLines	object	Có đăng ký nhiều đường dây điện thoại.
10	SeniorCitizen	object	Khách hàng có phải khách hàng cao tuổi hay không.
11	Partner	object	Khách hàng có bạn đời (vợ/chồng) hay không.
12	Dependents	object	Khách hàng có người phụ thuộc (con cái, người thân...) hay không.
13	PhoneService	object	Khách hàng có đăng ký dịch vụ điện thoại hay không.
14	InternetService	object	Loại hình kết nối internet.
15	OnlineSecurity	object	Khách hàng có đăng ký dịch vụ bảo mật trực tuyến hay không.
16	OnlineBackup	object	Khách hàng có đăng ký dịch vụ sao lưu dữ liệu trực tuyến hay không.
17	DeviceProtection	object	Khách hàng có đăng ký dịch vụ bảo vệ thiết bị hay không.
18	TechSupport	object	Khách hàng có đăng ký dịch vụ hỗ trợ kỹ thuật hay không.
19	StreamingTV	object	Khách hàng có đăng ký dịch vụ truyền hình trực tuyến hay không.
20	StreamingMovies	object	Khách hàng có đăng ký dịch vụ xem phim trực tuyến hay không.
21	PaperlessBilling	object	Khách hàng có lựa chọn thanh toán không dùng hóa đơn giấy hay không.


Bảng 1. Mô tả bộ dữ liệu

3. PHƯƠNG PHÁP PHÂN TÍCH

3.1 Quy trình phân tích

Để giải quyết bài toán dự báo khách hàng rời bỏ, chúng tôi đã đặt ra một bài toán phân loại nhị phân, với mục tiêu dự đoán khách hàng có rời bỏ dịch vụ hay không dựa trên dữ liệu lịch sử của khách hàng. Dữ liệu sử dụng bao gồm các thông tin về đặc điểm cá nhân, loại hình dịch vụ, thời gian sử dụng, hợp đồng và các yếu tố liên quan đến chi phí thanh toán.

Quy trình phân tích được thực hiện theo trình tự theo sơ đồ tại Hình 3 dưới đây:



Hình 3. Quy trình phân tích

Quy trình bắt đầu từ việc làm sạch dữ liệu thô, sau đó đi qua các bước tiền xử lý và chuẩn bị dữ liệu. Sau đó, dữ liệu được đưa vào huấn luyện qua các mô hình khác nhau và cuối cùng là đánh giá kết quả để tìm ra giải pháp tối ưu.

3.2 Các thuật toán và kĩ thuật sử dụng

3.2.1. Kĩ thuật tiền xử lý dữ liệu

Để đảm bảo chất lượng đầu vào cho mô hình, chúng tôi áp dụng các kỹ thuật như làm sạch dữ liệu, kỹ thuật đặc trưng (Feature Engineering), mã hóa (Encoding), chuẩn hóa (Scaling).

3.2.2. Các thuật toán mô hình hoá

Chúng tôi thực nghiệm trên 5 thuật toán học máy phổ biến để so sánh hiệu quả: Logistic Regression, Support Vector Machine (SVM), Decision Tree, Random Forest, K-Nearest Neighbors (KNN).


3.2.3. Các chỉ số đánh giá

Hiệu năng của các mô hình được đo lường dựa trên bộ 4 chỉ số: Accuracy, Precision, Recall và ROC-AUC. Trong đó chúng tôi đặc biệt chú trọng vào Recall và ROC-AUC để đánh giá khả năng phát hiện đúng tập khách hàng rời bỏ.

4. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU (EDA)

4.1 Tổng quan tỷ lệ rời bỏ

Bước đầu tiên trong quá trình phân tích khám phá dữ liệu là xem xét sự phân bố của biến mục tiêu **Churn**. Biểu đồ dưới đây thể hiện tỷ lệ giữa nhóm khách hàng tiếp tục sử dụng dịch vụ và nhóm khách hàng đã rời bỏ.



Hình 4.1. Tỷ lệ phân bố khách hàng Rời bỏ và Không rời bỏ

Dựa vào Hình 4.1, chúng tôi rút ra các nhận xét quan trọng sau:

- **Tỷ lệ rời bỏ (Churn Rate):** Trong tổng số 7.043 khách hàng được ghi nhận, có **1.869** khách hàng đã rời bỏ dịch vụ, chiếm tỷ lệ khoảng **26,5%**.
- **Tỷ lệ giữ chân (Retention Rate):** Phần lớn khách hàng (5.174 người) vẫn đang tiếp tục sử dụng dịch vụ, chiếm **73,5%**.
- **Vấn đề mất cân bằng dữ liệu:** Có sự chênh lệch rõ rệt giữa hai lớp dữ liệu (tỷ lệ xấp xỉ 1:3). Nhóm khách hàng "Không rời bỏ" (No) chiếm ưu thế áp đảo so với nhóm "Rời bỏ" (Yes).

Ý nghĩa: Sự mất cân bằng này cho thấy nếu sử dụng độ chính xác (Accuracy) làm thước đo duy nhất, mô hình có thể đạt kết quả cao ảo nhưng lại thất bại trong việc phát hiện khách hàng rời bỏ. Đây chính là cơ sở thực tiễn khẳng định sự cần thiết của việc áp dụng các chỉ số đánh giá chuyên sâu như **Recall, Precision, ROC-AUC** mà chúng tôi đã đề cập tại phần Phương pháp phân tích (Mục 3.2.3).

4.2 Nhóm khách hàng cao tuổi lại có tỉ lệ rời bỏ cao hơn so với nhóm khách hàng trẻ tuổi

Thông thường, chúng ta nghĩ rằng người cao tuổi (Senior Citizens) là nhóm khách hàng ngại thay đổi và có độ trung thành cao. Tuy nhiên, khi quan sát biểu đồ (Hình 4.2 bên trái) chúng tôi nhận thấy nhóm khách hàng cao tuổi có tỷ lệ rời bỏ cao hơn đáng kể so với nhóm trẻ tuổi. Cụ thể, tỷ lệ rời bỏ của nhóm này lên tới 41,7%. Kết quả này cho thấy nhóm khách hàng cao tuổi là phân khúc nhạy cảm, cần thay đổi mô hình dịch vụ hiện tại để giữ chân nhóm khách hàng này.

Khách hàng cao tuổi rời bỏ nhiều không phải vì giá mà vì sự bất lực trước công nghệ. Nhìn vào biểu đồ (Hình 4.2 – Tech Support), nhóm người cao tuổi không sử dụng dịch vụ hỗ trợ kỹ thuật có tỉ lệ rời bỏ rất cao lên đến 50,6%. Ngược lại, khi có sử dụng dịch vụ hỗ trợ, tỉ lệ rời bỏ giảm xuống mức an toàn (19,6%). Điều này cho thấy người cao tuổi rời bỏ vì gặp khó khăn khi sử dụng dịch vụ (gặp sự cố kỹ thuật) nhưng không có sự hỗ trợ dẫn đến quyết định huỷ dịch vụ.


Khi phân tích sâu hơn cấu trúc gia đình của nhóm khách hàng cao tuổi thông qua biến tổng hợp FamilyCluster (Hình 4.2 – FamilyCluster), kết quả cho thấy sự khác biệt rõ rệt về tỷ lệ rời bỏ. Nhóm khách hàng cao tuổi sống một mình (Độc thân) ghi nhận tỷ lệ rời bỏ cao nhất (40,2%), trong khi nhóm có bạn đời và người phụ thuộc có mức rời bỏ thấp hơn đáng kể. Điều này cho thấy yếu tố gia đình đóng vai trò quan trọng trong việc duy trì sự gắn bó của khách hàng cao tuổi, đồng thời xác định nhóm cao tuổi sống một mình là phân khúc có rủi ro rời bỏ cao và cần được ưu tiên trong các hoạt động chăm sóc khách hàng.



Hình 4.2. Phân tích tỷ lệ rời bỏ và các yếu tố tác động đến nhóm khách hàng cao tuổi

Chiến lược rút ra: Đối với nhóm khách hàng cao tuổi, thay vì giảm giá cước hay tặng các tiện ích bổ sung thì chiến lược giữ chân cần tập trung vào sự an tâm khi sử dụng dịch vụ, đó là dịch vụ hỗ trợ kỹ thuật (Tech Support). Chủ động tặng kèm gói dịch vụ hỗ trợ miễn phí cho khách hàng cao tuổi được xem là giải pháp hiệu quả về mặt chi phí, đặc biệt khi so sánh với các khoản đầu tư cần thiết để thu hút khách hàng mới nhằm bù đắp tỷ lệ rời bỏ.

4.3 Dịch vụ Fiber Optic (Cáp quang) mang lại doanh thu cao nhưng lại có tỷ lệ rời bỏ cao nhất



Hình 4.3. Phân tích hành vi rời bỏ của nhóm khách hàng Fiber Optic

Phân tích nhóm khách hàng sử dụng dịch vụ Fiber Optic cho thấy một nghịch lý rõ rệt giữa mức giá và tỷ lệ rời bỏ. Mặc dù đây là phân khúc có mức cước trung bình cao nhất, **92 USD** mỗi tháng, nhóm khách hàng này lại ghi nhận tỷ lệ rời bỏ ở mức cao, xấp xỉ **42%**. Nguyên nhân chủ yếu xuất phát từ khoảng cách giữa giá cả và giá trị cảm nhận, đặc biệt trong các tình huống phát sinh sự cố kỹ thuật khi dịch vụ không đi kèm hỗ trợ chuyên biệt. Kết quả cho thấy việc thiếu Tech Support làm gia tăng mạnh nguy cơ rời bỏ, trong khi sự hiện diện của dịch vụ hỗ trợ kỹ thuật giúp giảm đáng kể tỷ lệ rời bỏ ở nhóm khách hàng Fiber Optic.

Bên cạnh vai trò của hỗ trợ kỹ thuật, chúng tôi phân tích mở rộng với biến *TotalService* để làm rõ tác động của hiệu ứng hệ sinh thái đến hành vi rời bỏ. Những khách hàng chỉ sử dụng Fiber Optic đơn lẻ hoặc kèm rất ít dịch vụ bổ sung (*TotalServices* = 1 hoặc 2) ghi nhận tỷ lệ rời bỏ cao lên tới **59,2%**, phản ánh mức chi phí chuyển đổi thấp. Ngược lại, khi khách hàng sử dụng đồng thời nhiều dịch vụ (7 – 8 dịch vụ) trong cùng một hệ sinh thái, tỷ lệ rời bỏ giảm sâu chỉ còn **8,3% - 17,4%**. Việc tích hợp các dịch vụ như truyền hình, bảo mật, sao lưu dữ liệu và hỗ trợ kỹ thuật không chỉ nâng cao giá trị cảm nhận mà còn làm gia tăng mức độ gắn kết, khiến quyết định rời bỏ trở nên tốn kém hơn về mặt trải nghiệm và tiện ích.

Chiến lược rút ra: Việc giữ chân khách hàng sử dụng Fiber Optic không nằm ở việc điều chỉnh giá, mà ở việc gia tăng mức độ gắn kết thông qua hỗ trợ kỹ thuật và hệ sinh thái dịch vụ. Thay vì cung cấp Fiber Optic như một dịch vụ đơn lẻ, doanh nghiệp cần định hướng phát triển các gói dịch vụ tích hợp, trong đó Tech Support đóng vai trò nền tảng và các dịch vụ giá trị gia tăng giúp nâng tổng số dịch vụ sử dụng lên một ngưỡng đủ cao. Khi đó, Fiber Optic không chỉ là một loại đường truyền internet, mà trở thành trung tâm của một hệ sinh thái giải trí và bảo mật, khiến khách hàng không thể rời đi. Cách tiếp cận này góp phần giảm đáng kể tỷ lệ rời bỏ và bảo vệ nguồn doanh thu từ nhóm khách hàng có giá trị cao.

4.4 Tổng hợp phân tích

Qua quá trình phân tích khám phá dữ liệu (EDA), quan sát được hai hành vi khách hàng đáng chú ý:

- **Nhóm khách hàng cao tuổi là nhóm dễ rời bỏ cần được quan tâm.** Tỷ lệ rời bỏ ở nhóm này cao hơn đáng kể so với mức trung bình, phản ánh những khó khăn trong việc tiếp cận và xử lý các vấn đề kỹ thuật, đặc biệt ở những khách hàng sống một mình hoặc thiếu sự hỗ trợ từ gia đình. Việc không được cung cấp dịch vụ hỗ trợ kỹ thuật phù hợp làm gia tăng nhanh chóng mức độ không hài lòng và thúc đẩy quyết định chấm dứt hợp đồng.
- **Dịch vụ Internet cáp quang thể hiện rõ nhất mâu thuẫn giữa giá trị kinh tế và mức độ gắn bó của khách hàng.** Mặc dù mang lại doanh thu cao, dịch vụ cáp quang (Fiber Optic) lại đi kèm tỷ lệ rời bỏ lớn, đặc biệt ở những khách hàng chỉ sử dụng số lượng dịch vụ hạn chế. Phân tích cho thấy việc thiếu các

dịch vụ hỗ trợ và hỗ trợ kỹ thuật khiến mức giá cao không được cảm nhận là tương xứng, trong khi những khách hàng được tích hợp vào một hệ sinh thái dịch vụ đa dạng có xu hướng duy trì hợp đồng ổn định hơn.

5. XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH

5.1 Chuẩn bị dữ liệu huấn luyện

Để đảm bảo mô hình dự đoán có thể hoạt động tối ưu, giai đoạn chuẩn bị dữ liệu huấn luyện cụ thể như sau:

Làm sạch dữ liệu (Data Cleaning)

- Xử lý biến TotalCharges (chuyển từ Object sang Numeric) và SeniorCitizens (chuyển từ Numeric sang Object).
- Xử lý giá trị khuyết: Phát hiện 11 dòng thiếu dữ liệu ở TotalCharges vì ở những giá trị khuyết này tenure = 0 đều là khách hàng mới chưa phát sinh tổng hoá đơn nên điều khuyết bằng 0.
- Xử lý giá trị ngoại lai: Kiểm tra bộ dữ liệu không có giá trị ngoại lai.
- Loại bỏ thuộc tính: customerID không mang ý nghĩa dự đoán

Kỹ thuật đặc trưng (Feature Engineering):

- Biến FamilyCluster: Được tổng hợp từ 2 cột Partner và Dependents để phân loại quy mô hộ gia đình.
- Biến TotalServices: Đếm tổng số dịch vụ khách hàng đang sử dụng để đo lường mức độ gắn kết với hệ sinh thái.
- Biến AvgPricePerService: Tính cước phí trung bình trên mỗi dịch vụ để đánh giá mức độ "đắt / rẻ" thực tế.
- Biến SupportPackage: Đếm số lượng các gói hỗ trợ kỹ thuật (bảo mật, sao lưu, hỗ trợ) mà khách hàng đăng ký.
- Biến HighRiskProfile: Nhận diện nhóm rủi ro cao nhất (dùng Hợp đồng theo tháng kết hợp thanh toán Séc điện tử).

Mã hoá nhóm thuộc tính định tính (Encoding categorical data):

- Mã hoá biến mục tiêu Churn: Yes = 1, No = 0.
- Sử dụng One-Hot encode để chuyển đổi các biến định tính sang dạng số học.

Chuẩn hoá nhóm thuộc tính định lượng (Scaling numerical data): Sử dụng StandardScaler để đưa các biến định lượng về cùng một thang đo chuẩn.

Chia tập dữ liệu (Splitting data): Train (80%) - Test (20%), sử dụng Stratify theo biến mục tiêu y (Churn) để đảm bảo tỷ lệ khách hàng rời bỏ được phân bố đồng đều giữa tập huấn luyện và tập kiểm tra.

5.2 Kết quả huấn luyện ban đầu

Sử dụng toàn bộ thuộc tính, thực hiện huấn luyện trên 5 thuật toán phân loại phổ biến: Logistic Regression, K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Decision Tree và Random Forest.

Đánh giá đa chiều các chỉ số: Accuracy, Recall, Precision và ROC-AUC.

Mô hình	Accuracy	Recall (Churn)	Precision (Churn)	ROC-AUC
Logistic Regression	0.8020	0.5455	0.6518	0.8422
Random Forest	0.7899	0.5027	0.6309	0.8220
Support Vector Machine	0.7949	0.5000	0.6471	0.7953
K-Nearest Neighbors	0.7587	0.5214	0.5478	0.7662
Decision Tree	0.7750	0.5428	0.5817	0.7619

Bảng 5.2. Kết quả đánh giá 5 mô hình phân loại

Nhận xét: Logistic Regression đang dẫn đầu về chỉ số ROC-AUC (0.8422) và Accuracy (80.2%). Chỉ số Recall và Precision tốt nhất (0.5455 và 0.6518). Tuy nhiên chỉ số Recall chỉ ở mức 54% cho thấy mô hình đang bỏ sót gần một nửa số lượng khách hàng rời bỏ thực tế.

5.3 Mức độ quan trọng của biến

Áp dụng phương pháp đánh giá tổng hợp từ 5 kỹ thuật khác nhau để đảm bảo tính khách quan giữa các mô hình:

- Correlation Analysis: Tương quan tuyến tính
- Logistic Regression Coefficients: Trọng số của phương trình hồi quy
- RF Feature Importance: Đánh giá mức đóng góp của biến trong cây quyết định
- Permutation Importance: Đánh giá độ quan trọng bằng cách xáo trộn dữ liệu trên tập test
- Recursive Feature Elimination: Loại bỏ đệ quy để tìm những biến tinh túy nhất

Sau khi quan sát kết quả tổng hợp từ 5 phương pháp (Total Score), chúng tôi quyết định chọn bộ 9 biến gọn nhẹ nhưng hiệu quả cao nhất gồm:

Tên biến	tenure	Total Charges	Monthly Charges	Internet Service	Contract
Total Score	0.955	0.594	0.492	0.484	0.457
Tên biến	AvgPricePer Service	Paperless Billing	Total Services	Payment Method	
Total Score	0.305	0.231	0.226	0.205	

Bảng 5.3. Kết quả tổng hợp từ 5 phương pháp

5.4 Huấn luyện lại mô hình

Sau khi hoàn tất quá trình lựa chọn biến, chúng tôi tiến hành tái huấn luyện các mô hình trên 9 biến quan trọng nhất. Mục tiêu của việc này là kiểm chứng xem việc loại bỏ các biến nhiều có giúp mô hình duy trì được độ chính xác đồng thời giảm độ phức tạp tính toán và tăng khả năng giải thích.

Mô hình áp dụng: Tập trung vào 2 mô hình có hiệu năng tốt nhất ở giai đoạn đầu.

Phương pháp: Giữ nguyên giai đoạn tiền xử lý, kỹ thuật GridSearchCV kết hợp cross-validation để tìm bộ tham số tối ưu theo độ đo ROC-AUC

Kết quả huấn luyện trên tập biến rút gọn (9 biến):

Mô hình	Accuracy	Recall (Churn)	Precision (Churn)	ROC-AUC
Random Forest	0.7637	0.7380	0.5401	0.8408
Logistic Regression	0.7956	0.5401	0.6352	0.8358

Bảng 5.4. Kết quả sau khi huấn luyện lại mô hình

Nhận xét: Việc giảm số lượng biến từ 24 xuống 9 hầu như không làm giảm hiệu năng dự đoán thậm chí với Random Forest kết quả còn trở nên tốt hơn so với trước, chứng tỏ 9 biến này thực sự nắm giữ thông tin cốt lõi.

Sự cải thiện rõ rệt nhất nằm ở mô hình Random Forest sau khi tinh chỉnh: recall từ mức 0.5027 lên tới 0.738. Đây là một dấu hiệu rất tốt, cho thấy đã tìm ra được thêm 23% số khách hàng có nguy cơ rời bỏ mà mô hình cũ bỏ sót. Mặc dù Accuracy giảm nhẹ và Precision giảm, nhưng chỉ số tổng quát ROC-AUC lại đạt mức cao nhất (0.8408).

5.5 Tối ưu hoá ngưỡng

Trong bài toán dự báo rời bỏ, việc sử dụng ngưỡng mặc định 0.5 không phải lúc nào cũng tối ưu về mặt lợi ích kinh doanh. Vì khi dự đoán sai một khách hàng rời bỏ, sẽ mất đi doanh thu của khách hàng đó và phải tốn chi phí cao để tìm khách hàng thay thế.

Nhưng việc dự đoán nhầm một khách hàng trung thành chỉ tốn một khoản phí nhỏ để chăm sóc khách hàng

Threshold	Recall	Precision	Accuracy
0.3	0.8877	0.4554	0.6884
0.4	0.8289	0.5000	0.7346
0.5	0.7380	0.5401	0.7637
0.6	0.6578	0.5857	0.7857

Hình 5.5. Kết quả tối ưu hoá ngưỡng với mô hình RF

Dựa vào tính rủi ro của việc dự đoán nhầm khách hàng sẽ rời bỏ, nhóm quyết định chọn ngưỡng 0.4 làm ngưỡng quyết định: cứ 100 khách hàng rời bỏ mô hình sẽ dự đoán được khoảng 83 người trong đó (Recall = 0.8289), Mặc dù, tỷ lệ dự đoán đúng chỉ là 50% (Precision = 0.5) tuy nhiên việc chăm sóc nhầm một người để tránh nguy cơ một người rời bỏ là cái giá chấp nhận được trong bài toán dự đoán rời bỏ. Bởi vì chi phí chăm sóc khách hàng là thấp hơn nhiều so với mất đi doanh thu. Chỉ số accuracy 0.7346 vẫn ở mức khá tốt

6. KẾT LUẬN

Qua đề tài này, chúng tôi đã xây dựng một quy trình phân tích và khám phá dữ liệu tổng quát nhằm dự đoán hành vi rời bỏ dịch vụ của khách hàng trong lĩnh vực viễn thông. Bằng cách kết hợp phân tích khám phá dữ liệu, các mô hình học máy và trực quan hóa qua Power BI. Bên cạnh đó, chúng tôi cũng đã làm rõ những yếu tố quan trọng ảnh hưởng đến quyết định rời bỏ của khách hàng, đồng thời chuyển đổi dữ liệu thô thành những thông tin chiến lược có tính ứng dụng thực tiễn.

Kết quả phân tích cho thấy hai hành vi rời bỏ của khách hàng đáng chú ý. Thứ nhất, nhóm khách hàng cao tuổi là phân khúc có rủi ro rời bỏ cao nhất. Thứ hai, ở nhóm khách hàng sử dụng Internet cáp quang, tỷ lệ rời bỏ cao phản ánh khoảng cách giữa chi phí và giá trị cảm nhận, đặc biệt khi dịch vụ thiếu các thành phần hỗ trợ và hỗ trợ kỹ thuật.

Chúng tôi đã triển khai so sánh các mô hình và áp dụng phương pháp đánh giá tổng hợp từ 5 kỹ thuật khác nhau chọn ra 9 biến quan trọng có hiệu quả cao nhất để tái huấn luyện kết hợp fine-tuning 2 mô hình có hiệu năng tốt nhất ở giai đoạn đầu. Thu được kết quả mô hình Random Forest tốt hơn so với việc sử dụng toàn bộ biến ban đầu. Việc giảm 24 biến xuống 9 biến hầu như không làm giảm hiệu năng dự đoán với Logistic Regression, chứng tỏ 9 biến này thực sự nắm giữ thông tin cốt lõi. Kết quả tối ưu hoá ngưỡng 0.4 giúp nhận biết được nhiều khách hàng sẽ rời bỏ hơn cho doanh nghiệp.

Đề tài sử dụng bộ dữ liệu tại một thời điểm nên chưa phản ánh được sự thay đổi hành vi khách hàng theo thời gian. Bên cạnh đó, dữ liệu còn thiếu các yếu tố định tính như mức độ hài lòng và trải nghiệm dịch vụ, khiến việc phân tích nguyên nhân rời bỏ chưa thật sự toàn diện. Ngoài ra, mô hình dự báo vẫn phụ thuộc vào chất lượng dữ liệu và chưa đánh giá hiệu quả của các chiến lược giữ chân trong môi trường thực tế. Đó là những hạn chế cần được cải thiện trong tương lai.

TÀI LIỆU THAM KHẢO

- [1] Kaggle.com. Link: [Telco Customer Churn Dataset](#) (Ngày truy cập 04/12/2025)
- [2] Công cụ GridSearchCV. Link: [GridSearchCV — scikit-learn 1.8.0 documentation](#) (Ngày truy cập 08/12/2025)

PHỤ LỤC PHÂN CÔNG NHIỆM VỤ

STT	Thành viên	Nhiệm vụ
1	Trương Thế Minh Khánh	- Làm sạch dữ liệu - Kỹ thuật đặc trưng (Feature Engineering) - Mã hóa biến (Encoding) và chuẩn hóa dữ liệu (Scaling) - Chuẩn bị bộ dữ liệu đầu vào cho mô hình - Tham gia xây dựng slide và viết phần mô tả dữ liệu, phương pháp
2	Trần Anh Duy	- Thực hiện phân tích khám phá dữ liệu (EDA) - Phân tích các yếu tố ảnh hưởng đến tỷ lệ rời bỏ - Giải thích insight, trực quan hóa dữ liệu - Xây dựng nội dung insight - Viết phần phân tích và thảo luận kết quả
3	Nguyễn Văn Tiên	- Huấn luyện các mô hình dự đoán - Đánh giá mô hình bằng các chỉ số (Accuracy, Recall, ROC-AUC, ...) - So sánh và lựa chọn mô hình tối ưu - Trình bày kết quả trên slide và viết phần mô hình hóa